ارتباط وضعیت مصرف سیگار با شدت علائم افسردگی در بزرگسالان آمریکایی

گزارش فاز اول پروژه‌ی درس آمار — شناخت مطالعه، داده و آمار توصیفی

مسیر الف: NHANES 2021–2023

نام و نام خانوادگی: ریحانه علی‌پور

شماره‌ی دانشجویی:۴۰۱۱۰۸۵۳۴

پاییز ۱۴۰۵

خلاصه

در این پروژه بررسی می‌کنیم که آیا وضعیت مصرف سیگار با شدت علائم افسردگی در بزرگسالان آمریکا ارتباط دارد یا نه. برای سنجش علائم افسردگی از نمره‌ی PHQ-9و برای دسته‌بندی افراد از سه گروه «هرگز سیگاری»، «سیگاری سابق» و «سیگاری فعلی» استفاده کردیم.

پس از ادغام سه فایل داده و کنار گذاشتن افراد فاقد اطلاعات لازم، ۵۲۰۳ نفر در تحلیل باقی ماندند. در این نمونه، میانگین و میانه‌ی نمره‌ی افسردگی در گروه سیگاری‌های فعلی بیشتر بود. البته این مقایسه به‌تنهایی نشان نمی‌دهد که سیگار علت افزایش علائم افسردگی است. با استفاده از وزن‌های نمونه‌گیری نیز بعضی از برآوردها تغییر کردند.

فهرست مطالب

خلاصه ۱

۱ سؤال آماری و طراحی مطالعه ۳

۲ منشأ داده و ساختار آن ۳

۱.۲ منشأ و سازوکار جمع‌آوری ۳

۲.۲ فایل‌ها و کلید ادغام ۳

۳ نمونه‌گیری، وزن‌ها و قابلیت تعمیم ۴

۴ طبقه‌بندی متغیرها ۵

۵ تعریف جمعیت تحلیلی ۶

۶ ممیزی کیفیت داده ۶

۷ جدول‌های فراوانی و خلاصه‌ی عددی ۷

۸ مصورسازی ۹

۹ مقایسه‌ی توصیفی اولیه ۱۱

۱۰ مقایسه‌ی خلاصه‌ی ساده و وزن‌دار ۱۲

۱۱ سؤال نهایی، تناسب داده و محدودیت‌ها ۱۳

منابع ۱۴

۱ سؤال آماری و طراحی مطالعه

سؤال اصلی: در افراد ۲۰ سال به بالا، آیا نمره‌ی افسردگی در گروه‌های مختلف مصرف سیگار با هم تفاوت دارد؟ همچنین می‌خواهیم ببینیم آیا این تفاوت با در نظر گرفتن سن، جنس و درآمد هم باقی می‌ماند.

متغیر پاسخ، نمره‌ی PHQ-9است و متغیر اصلی توضیح‌دهنده، وضعیت مصرف سیگار است. سن، جنس و نسبت درآمد به خط فقر نیز متغیرهایی هستند که در مراحل بعدی بررسی می‌کنیم.

انتظار اولیه این است که میانگین نمره‌ی افسردگی در گروه سیگاری‌های فعلی بیشتر باشد. واحد بررسی در این پروژه هر فرد است و شناسه‌ی او در فایل‌ها SEQN است.

۲ منشأ داده و ساختار آن

۱.۲ منشأ و سازوکار جمع‌آوری

داده‌ها از پیمایش ملی سلامت و تغذیه‌ی آمریکا (NHANES) گرفته شده‌اند. این پیمایش را مرکز ملی آمار سلامت آمریکا (NCHS) اجرا می‌کند. در این پروژه از داده‌های اوت ۲۰۲۱ تا اوت ۲۰۲۳ استفاده کردیم.

در این پیمایش، افراد ابتدا به پرسش‌ها پاسخ می‌دهند و سپس برای معاینه به مرکز سیار معاینه (MEC) مراجعه می‌کنند. پرسش‌نامه‌ی افسردگی PHQ-9نیز در همین بخش تکمیل می‌شود. فایل‌های عمومی داده را از وب‌سایت CDC دریافت کردیم.

این مطالعه مقطعی و مشاهده‌ای است؛ یعنی اطلاعات افراد در یک بازه‌ی زمانی جمع‌آوری شده و پژوهشگر هیچ مداخله‌ای انجام نداده است.

۲.۲ فایل‌ها و کلید ادغام

برای این پروژه سه فایل زیر را استفاده کردیم. شناسه‌ی SEQN در هر فایل یکتا بود و از آن برای وصل کردن اطلاعات افراد استفاده شد. با اینکه هر فرد در هر فایل یک ردیف دارد، طرح نمونه‌گیری NHANES افراد را در خانوارها و واحدهای نمونه‌گیری گروه‌بندی می‌کند.

جدول ۱: فایل‌های استفاده‌شده

فایل	تعداد ردیف	تعداد ستون	تعداد SEQN یکتا	محتوا / بازه‌ی سنی
DEMO_L	۱۱۹۳۳	۲۷	۱۱۹۳۳	جمعیت‌شناختی، وزن‌ها و متغیرهای طرح نمونه‌گیری؛ ۰ تا ۸۰
DPQ_L	۶۳۳۷	۱۱	۶۳۳۷	پرسش‌نامه‌ی افسردگی PHQ-9؛ ۱۸ تا ۸۰
SMQ_L	۹۰۱۵	۹	۹۰۱۵	مصرف دخانیات؛ ۱۲ تا ۸۰

سه فایل را با استفاده از شناسه‌ی SEQN به هم وصل کردیم و فایل DEMO_L را مبنا قرار دادیم. تعداد ردیف‌ها قبل و بعد از ادغام ۱۱۹۳۳ باقی ماند؛ بنابراین ادغام باعث زیاد شدن ردیف‌های تکراری نشد. اگر فردی در یکی از فایل‌ها اطلاعاتی نداشته باشد، متغیرهای مربوط به همان فایل برای او خالی می‌ماند.

۳ نمونه‌گیری، وزن‌ها و قابلیت تعمیم

نمونه‌ی NHANES به‌صورت تصادفی ساده انتخاب نشده است؛ نمونه‌گیری چندمرحله‌ای و طبقه‌بندی‌شده است. جامعه‌ی هدف، افرادی هستند که در خانه و محل‌های معمول زندگی در آمریکا ساکن‌اند. بعضی گروه‌ها عمداً بیشتر نمونه‌گیری شده‌اند تا اطلاعات کافی درباره‌ی آن‌ها به دست بیاید. به همین دلیل، افراد نمونه وزن‌های یکسانی ندارند.

وزن نمونه‌گیری نشان می‌دهد هر فرد در نمونه نماینده‌ی چند نفر از جمعیت است. چون نمره‌ی PHQ-9در بخش معاینه‌ی MEC جمع‌آوری شده، برای محاسبه‌ی برآوردهای وزن‌دار از وزن WTMEC2YR استفاده کردیم. دو متغیر SDMVSTRA و SDMVPSU نیز اطلاعات طبقه‌ها و واحدهای نمونه‌گیری را نگه می‌دارند و برای محاسبه‌ی درست خطای استاندارد لازم‌اند.

نتایج وزن‌دار را می‌توان با احتیاط به بزرگسالان ۲۰ سال به بالای آمریکا در همین دوره تعمیم داد. این نتایج برای کشورهای دیگر یا افرادی که در مراکز اقامتی زندگی می‌کنند قابل تعمیم نیست. همچنین چون داده‌ها مقطعی‌اند، از آن‌ها نمی‌توان رابطه‌ی علت و معلولی نتیجه گرفت.

۴ طبقه‌بندی متغیرها

جدول ۲: متغیرهای اصلی، نوع و نقش آن‌ها

متغیر	تعریف	نوع و مقیاس	نقش
phq9	مجموع ۹ آیتم PHQ-9 (هر آیتم ۰ تا ۳)	کمی گسسته (۰ تا ۲۷)	پاسخ
phq9_ge10	نمره‌ی PHQ-9 بزرگ‌تر یا مساوی ۱۰	دودویی (مشتق)	پیامد دودویی (فاز ۲)
smoke	وضعیت سیگار: هرگز / سابق / فعلی	اسمی سه‌سطحی	توضیحی اصلی
RIDAGEYR	سن به سال (۸۰ = ۸۰ و بالاتر)	کمی پیوسته	کنترل
sex (RIAGENDR)	جنس	دودویی	کنترل
INDFMPIR	نسبت درآمد خانوار به خط فقر (۰ تا ۵؛ ۵ = ۵ یا بیشتر)	کمی پیوسته	کنترل
RIDRETH3	نژاد / قومیت	اسمی (۶ دسته)	توصیفی
DMDEDUC2	تحصیلات	ترتیبی (۵ سطح)	توصیفی
WTMEC2YR, SDMVSTRA, SDMVPSU	وزن نمونه‌گیری و متغیرهای طرح (طبقه و PSU)	کمی / شناسه	وزن‌دهی

نمره‌ی PHQ-9از جمع پاسخ‌های ۹ سؤال DPQ010 تا DPQ090 به دست آمد. هر سؤال از ۰ تا ۳ نمره دارد؛ اگر حتی یکی از پاسخ‌ها نامعتبر یا خالی بود، نمره‌ی کل را محاسبه نکردیم. کدهای ۷ و ۹ به‌عنوان پاسخ نامعتبر در نظر گرفته شدند. سؤال DPQ100 در محاسبه‌ی نمره وارد نمی‌شود.

برای ساخت متغیر سیگار از دو سؤال استفاده کردیم: افرادی که در طول عمر کمتر از ۱۰۰ نخ سیگار کشیده‌اند در گروه «هرگز» قرار گرفتند؛ کسانی که حداقل ۱۰۰ نخ کشیده‌اند ولی اکنون سیگار نمی‌کشند، «سابق» و کسانی که هنوز هر روز یا بعضی روزها سیگار می‌کشند، «فعلی» در نظر گرفته شدند. بنابراین گروه «هرگز» ممکن است افرادی را هم شامل شود که تعداد کمی سیگار کشیده‌اند.

۵ تعریف جمعیت تحلیلی

برای ورود به تحلیل، افراد باید حداقل ۲۰ سال داشته باشند، به هر ۹ سؤال PHQ-9پاسخ معتبر داده باشند و وضعیت مصرف سیگارشان مشخص باشد. تعداد افراد در هر مرحله در جدول زیر آمده است.

جدول ۳: جریان انتخاب جمعیت تحلیلی

مرحله	دلیل	تعداد حذف‌شده	تعداد باقی‌مانده
همه‌ی افراد در DEMO_L	–	۰	۱۱۹۳۳
سن ۲۰ سال و بالاتر	کودکان و افراد ۱۸–۱۹ ساله خارج می‌شوند	۴۱۲۴	۷۸۰۹
دارای رکورد DPQ	افراد فقط مصاحبه‌شده‌اند و در بخش معاینه شرکت نکرده‌اند؛ PHQ-9 در MEC اجرا می‌شود	۱۷۴۵	۶۰۶۴
نمره‌ی PHQ-9 کامل	حداقل یک آیتم PHQ-9 بی‌پاسخ، «رد کرد» یا «نمی‌دانم» بوده است	۸۵۴	۵۲۱۰
وضعیت سیگار مشخص	وضعیت سیگار نامعلوم (پاسخ ۷ یا ۹ یا بی‌پاسخ)	۷	۵۲۰۳

در مجموع ۸۵۴ نفر به دلیل ناقص بودن پاسخ‌های PHQ-9از تحلیل کنار گذاشته شدند. حذف افراد دارای پاسخ ناقص ممکن است نتایج را تحت تأثیر قرار دهد؛ بنابراین این موضوع را در بخش محدودیت‌ها در نظر می‌گیریم.

۶ ممیزی کیفیت داده

جدول ۴: وضعیت پاسخ آیتم‌های PHQ-9 در بزرگسالان دارای رکورد DPQ (n=6064)

آیتم	پاسخ معتبر (۰–۳)	رد کرد (۷)	نمی‌دانم (۹)	بی‌پاسخ (NaN)
DPQ010	۵۲۵۲	۵	۱۶	۷۹۱
DPQ020	۵۲۶۲	۳	۷	۷۹۲
DPQ030	۵۲۶۳	۳	۴	۷۹۴
DPQ040	۵۲۶۰	۳	۵	۷۹۶
DPQ050	۵۲۶۴	۰	۳	۷۹۷
DPQ060	۵۲۶۰	۳	۲	۷۹۹
DPQ070	۵۲۶۰	۲	۱	۸۰۱
DPQ080	۵۲۵۱	۴	۸	۸۰۱
DPQ090	۵۲۵۶	۰	۵	۸۰۳

جدول ۵: خلاصه‌ی ممیزی و تصمیم‌های اتخاذشده

موضوع	یافته	تصمیم و دلیل
مقادیر بسیار کوچک	در فایل‌های SAS مقدار صفر با این شکل خوانده می‌شود	گرد شدن به ۰، چون در واقع صفرند
کدهای ۷ و ۹ در PHQ-9	رد کرد: ۰ تا ۵ نفر؛ نمی‌دانم: ۱ تا ۱۶ نفر در هر آیتم	گمشده؛ نمره فقط با ۹ آیتم معتبر محاسبه می‌شود
آیتم‌های بی‌پاسخ PHQ-9	۷۹۱ تا ۸۰۳ نفر در هر آیتم	حذف از جمعیت تحلیلی (۸۵۴ نفر)؛ سوگیری احتمالی در محدودیت‌ها آمده است
سیگار: کدهای ۷، ۹ و بی‌پاسخ	۷ رد کرد، ۷ نمی‌دانم، ۱۵ بی‌پاسخ در بزرگسالان	وضعیت سیگار نامعلوم و حذف از جمعیت تحلیلی (۷ نفر در مرحله‌ی آخر)
ناسازگاری منطقی سیگار	۰ نفر «هرگز» با پاسخ SMQ040؛ ۰ نفر حداقل ۱۰۰ نخ بدون پاسخ SMQ040	نیازی به اقدام نبود
رکورد تکراری	SEQN در هر فایل و پس از ادغام یکتاست	نیازی به اقدام نبود
دامنه‌ی مقادیر	PHQ-9: ۰ تا ۲۶ (مجاز ۰ تا ۲۷)؛ سن ۲۰ تا ۸۰؛ INDFMPIR از ۰ تا ۵؛ هیچ وزن گمشده یا غیرمثبت نیست	هیچ مقدار غیرممکنی دیده نشد
سقف‌گذاری	سن ۸۰ یعنی «۸۰ و بالاتر»؛ INDFMPIR=۵ یعنی «۵ یا بیشتر»	مقادیر نگه داشته شد و در تفسیر لحاظ می‌شود
گمشدگی درآمد	۶۲۴ نفر (۱۲٫۰٪) در جمعیت تحلیلی	در این فاز حذف نشد؛ در رگرسیون فاز ۴ بررسی می‌شود
تحصیلات نامعلوم	۲ نفر با کد ۷ یا ۹	گمشده؛ اثر ناچیز

۷ جدول‌های فراوانی و خلاصه‌ی عددی

جدول‌های زیر برای جمعیت تحلیلی (n=5203) و بدون وزن هستند.

جدول ۶: وضعیت سیگار

وضعیت سیگار	تعداد	درصد
هرگز	۳۰۵۴	٪۵۸٫۷
سابق	۱۳۸۱	٪۲۶٫۵
فعلی	۷۶۸	٪۱۴٫۸

جدول ۷: جنس

جنس	تعداد	درصد
زن	۲۸۴۲	٪۵۴/۶
مرد	۲۳۶۱	٪۴۵/۴

جدول ۸: نژاد / قومیت

نژاد / قومیت	تعداد	درصد
سفیدپوست غیراسپانیایی‌تبار	۳۲۱۴	٪۶۱/۸
سیاه‌پوست غیراسپانیایی‌تبار	۵۹۷	٪۱۱/۵
سایر اسپانیایی‌تبارها	۴۹۷	٪۹/۶
سایر / چندنژادی	۳۳۹	٪۶/۵
مکزیکی‌آمریکایی	۳۲۸	٪۶/۳
آسیایی غیراسپانیایی‌تبار	۲۲۸	٪۴/۴

جدول ۹: تحصیلات

تحصیلات	تعداد	درصد
کمتر از کلاس ۹	۱۷۵	٪۳/۴
کلاس ۹ تا ۱۱	۳۷۱	٪۷/۱
دیپلم یا معادل	۱۰۶۹	٪۲۰/۵
کالج ناتمام یا کاردانی	۱۶۲۱	٪۳۱/۲
کارشناسی و بالاتر	۱۹۶۵	٪۳۷/۸
نامعلوم (کد ۷ یا ۹)	۲	٪۰/۰

در این نمونه، بیش از نیمی از افراد هرگز سیگار نکشیده‌اند و حدود ۱۵ درصد سیگاری فعلی‌اند. تعداد زنان کمی بیشتر از مردان است. همچنین بیشترین گروه تحصیلی، افراد دارای کارشناسی یا تحصیلات بالاتر هستند. این درصدها مربوط به نمونه‌ی ما هستند و لزوماً با ترکیب کل جمعیت آمریکا یکسان نیستند.

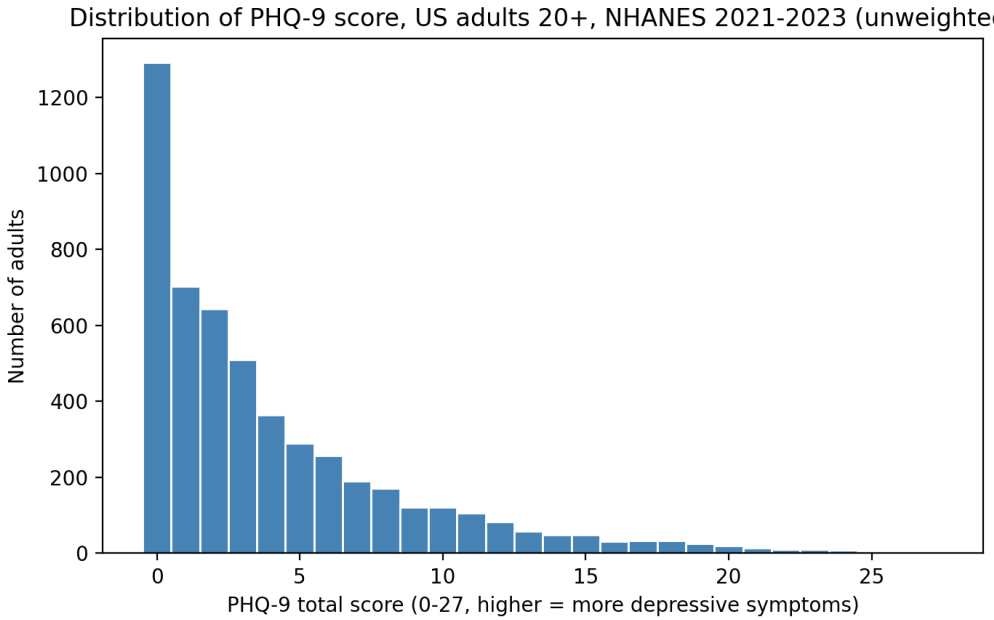
جدول ۱۰: خلاصه‌ی متغیرهای کمی (بدون وزن). INDFMPIR برای ۴۵۷۹ نفر موجود است

متغیر	n	میانگین	SD	کمینه	۱Q	میانه	۳Q	بیشینه	IQR / چولگی
نمره‌ی PHQ-9	۵۲۰۳	۴/۰۴	۴/۶۸	۰	۱	۲	۶	۲۶	۵/۰۰ / ۱/۶۶
سن (سال)	۵۲۰۳	۵۳/۷۴	۱۷/۰۴	۲۰	۳۹	۵۸	۶۸	۸۰	۲۹/۰۰ / -۰/۳۰
نسبت درآمد به خط فقر	۴۵۷۹	۳/۰۲	۱/۶۵	۰	۱/۵۳	۳	۵	۵	۳/۴۷ / -۰/۱۴

نمره‌ی PHQ-9توزیع نامتقارنی دارد و بیشتر افراد نمره‌های پایین گرفته‌اند؛ به همین دلیل، میانه و IQR تصویر

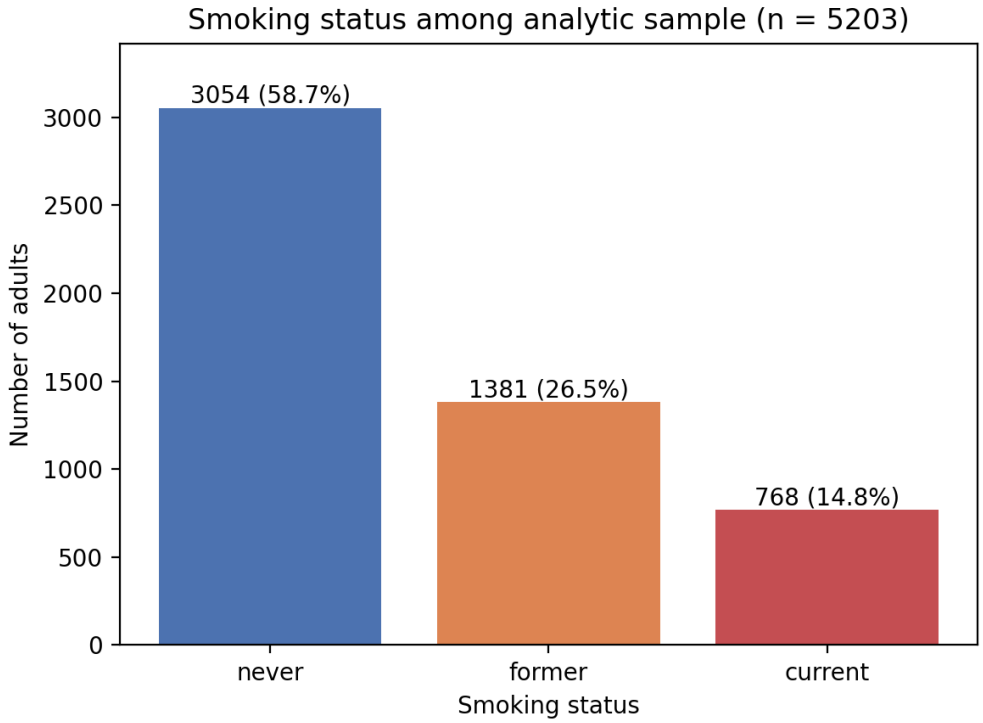
بهتری از مقدار معمول نمره می‌دهند. برای سن که توزیع متعادل‌تری دارد، میانگین و انحراف معیار هم قابل استفاده‌اند. متغیر درآمد در مقدار ۵ سقف دارد؛ یعنی مقدارهای بالاتر همگی با عدد ۵ ثبت شده‌اند.

۸ مصورسازی

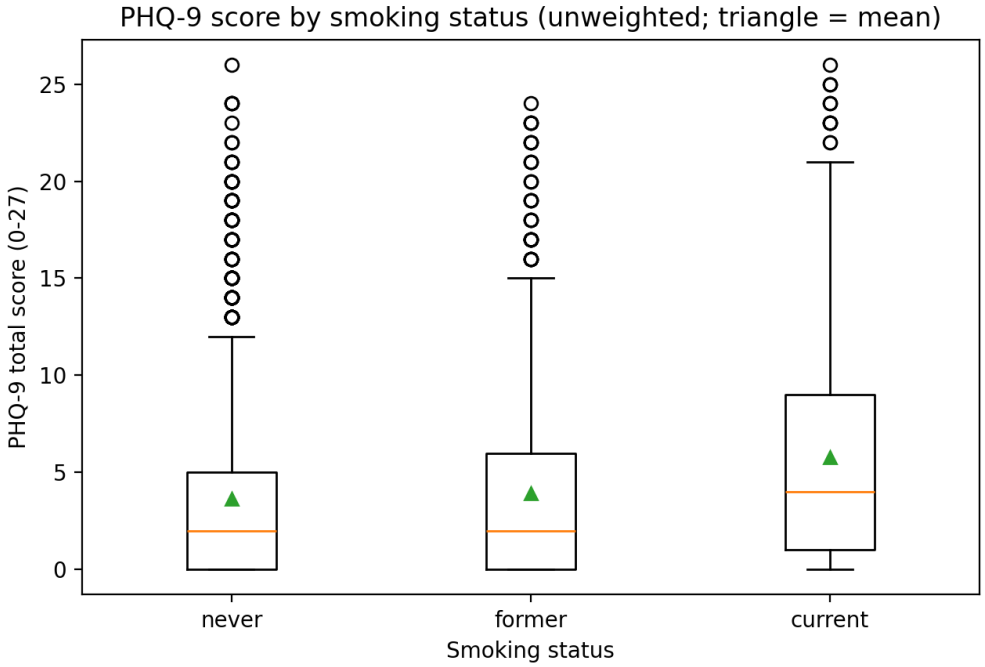


شکل ۱: توزیع نمره‌ی PHQ-9 (n= ۵۲۰۳، بدون وزن). محور افقی: نمره‌ی کل ۰ تا ۲۷؛ محور عمودی: تعداد افراد.

در این نمودار بیشتر افراد نمره‌ی پایینی دارند و تعداد کمی نمره‌های بالا گرفته‌اند. بنابراین توزیع نمره‌ها به سمت راست کشیده شده است.

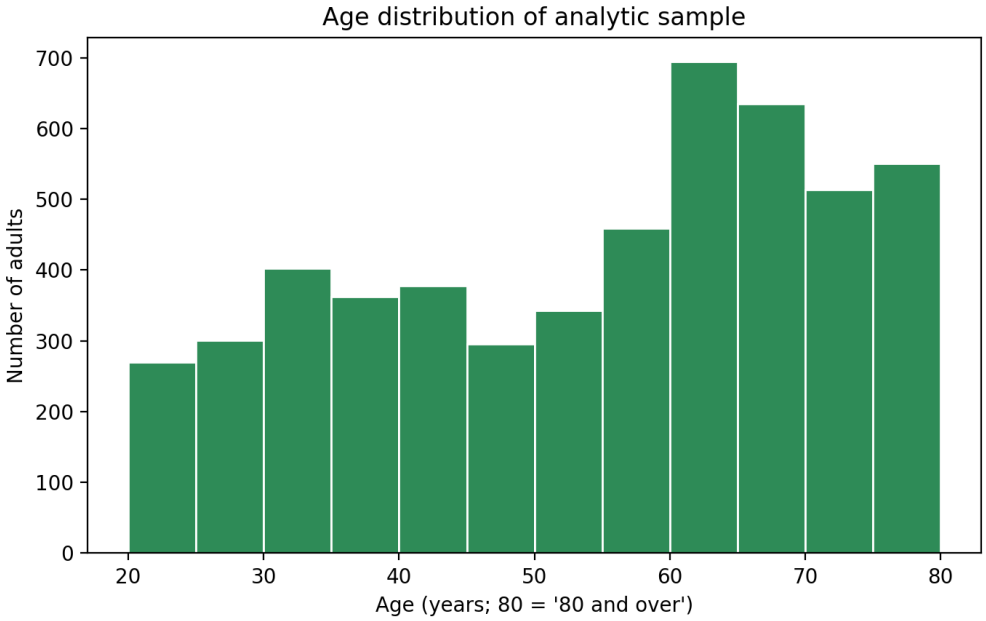


شکل ۲: وضعیت مصرف سیگار در جمعیت تحلیلی. محور افقی: گروه؛ محور عمودی: تعداد افراد (درصد روی هر ستون).



شکل ۳: نمره‌ی PHQ-9 به تفکیک وضعیت سیگار (بدون وزن؛ مثلث = میانگین). محور عمودی: نمره‌ی کل ۰ تا ۲۷.

در نمودار جعبه‌ای، نمره‌های گروه سیگاری‌های فعلی به‌طور کلی بالاتر دیده می‌شود. در هر سه گروه نیز چند مقدار خیلی بالا وجود دارد.



شکل ۴: توزیع سن در جمعیت تحلیلی. محور افقی: سن به سال (۸۰ = ۸۰ و بالاتر)؛ محور عمودی: تعداد افراد.

این نمودار نشان می‌دهد افراد نمونه از گروه‌های سنی مختلف انتخاب شده‌اند. در داده‌ها، سن ۸۰ برای همه‌ی افراد ۸۰ ساله و بالاتر ثبت شده است.

۹ مقایسه‌ی توصیفی اولیه

در این بخش میانگین و میانه‌ی نمره‌ی افسردگی را در سه گروه سیگار با هم مقایسه می‌کنیم. این مقایسه فقط توصیفی است.

جدول ۱۱: نمره‌ی PHQ-9 به تفکیک وضعیت سیگار (بدون وزن)

گروه	n	میانگین	SD	۱Q	میانه	۳Q	درصد با PHQ-9 ≥ ۱۰
هرگز	۳۰۵۴	۳٫۶۵	۴٫۳۷	۰	۲	۵	٪۱۰٫۸
سابق	۱۳۸۱	۳٫۹۳	۴٫۵۲	۰	۲	۶	٪۱۱٫۲
فعلی	۷۶۸	۵٫۷۷	۵٫۶۸	۱	۴	۹	٪۲۲٫۸

در این نمونه، میانگین و میانه‌ی نمره‌ی افسردگی در گروه سیگاری‌های فعلی از دو گروه دیگر بیشتر است. درصد افرادی که نمره‌ی ۱۰ یا بالاتر دارند نیز در این گروه بیشتر دیده می‌شود. میانگین گروه سیگاری‌های سابق به گروه افرادی که هرگز سیگار نکشیده‌اند نزدیک‌تر است. این‌ها تفاوت‌های مشاهده‌شده در نمونه‌اند و به‌تنهایی علت این تفاوت را مشخص نمی‌کنند.

جدول ۱۲: ویژگی‌های سه گروه (بدون وزن)

گروه	میانگین سن (سال)	درصد زنان	میانگین نسبت درآمد به خط فقر
هرگز	۵۱/۵	٪۵۹/۰	۳/۲۶
سابق	۵۹/۳	٪۴۹/۴	۳/۰۶
فعلی	۵۲/۶	٪۴۶/۵	۲/۰۴

سه گروه از نظر سن، جنس و درآمد هم با هم فرق دارند. برای مثال، میانگین درآمد گروه سیگاری‌های فعلی کمتر است و ترکیب جنسیتی آن‌ها نیز متفاوت است. این عوامل ممکن است با نمره‌ی افسردگی ارتباط داشته باشند؛ پس نمی‌توان تمام تفاوت نمره‌ها را فقط به وضعیت سیگار نسبت داد. در مراحل بعدی پروژه این عوامل را هم‌زمان بررسی می‌کنیم.

۱۰ مقایسه‌ی خلاصه‌ی ساده و وزن‌دار

در محاسبه‌ی میانگین وزن‌دار، مقدار هر فرد متناسب با وزن نمونه‌گیری او در محاسبه وارد می‌شود. برای نسبت‌ها نیز همین کار را روی متغیر صفر و یک انجام می‌دهیم. در این بخش از وزن WTMEC2YR استفاده کردیم. در این فاز فقط برآوردها را مقایسه می‌کنیم؛ محاسبه‌ی خطای استاندارد و فاصله‌ی اطمینان به مراحل بعد موکول می‌شود.

جدول ۱۳: مقایسه‌ی برآوردهای ساده و وزن‌دار

کمیت	بدون وزن	وزن‌دار	تفاوت (وزن‌دار - بدون وزن)
میانگین PHQ-9	۴/۰۳۷	۳/۹۶۴	-۰/۰۷۳
نسبت PHQ-9 ۱۰ $\geq$	۰/۱۲۷	۰/۱۲۲	-۰/۰۰۵
نسبت هرگز سیگاری	۰/۵۸۷	۰/۶۲۱	۰/۰۳۴
نسبت سیگاری سابق	۰/۲۶۵	۰/۲۳۵	-۰/۰۳۰
نسبت سیگاری فعلی	۰/۱۴۸	۰/۱۴۴	-۰/۰۰۴
نسبت زنان	۰/۵۴۶	۰/۵۰۹	-۰/۰۳۸
میانگین سن (سال)	۵۳/۷۳۹	۴۸/۸۰۴	-۴/۹۳۵

جدول ۱۴: میانگین PHQ-9 به تفکیک وضعیت سیگار، بدون وزن و وزن‌دار

گروه	n	میانگین بدون وزن	میانگین وزن‌دار
هرگز	۳۰۵۴	۳/۶۵	۳/۶۶
سابق	۱۳۸۱	۳/۹۳	۳/۸۶
فعلی	۷۶۸	۵/۷۷	۵/۴۲

وزن‌دهی باعث شد بعضی از برآوردها، به‌ویژه میانگین سن و درصد گروه‌های سیگاری، تغییر کنند. در مقابل،

میانگین کلی نمره‌ی PHQ-9تغییر زیادی نداشت. این تفاوت‌ها نشان می‌دهند که درصدهای ساده‌ی نمونه را نباید مستقیماً برابر با درصدهای جمعیت در نظر گرفت؛ چون افراد در نمونه وزن‌های متفاوتی دارند.

۱۱ تناسب داده با سؤال و محدودیت‌ها

تناسب داده با سؤال. هر دو متغیر اصلی، یعنی وضعیت سیگار و نمره‌ی افسردگی، برای افراد یکسان ثبت شده‌اند و تعداد افراد هر سه گروه برای مقایسه‌ی توصیفی کافی است. بنابراین این داده برای بررسی سؤال پروژه مناسب است.

محدودیت‌ها

- مقطعی بودن: اطلاعات در یک بازه‌ی زمانی جمع‌آوری شده‌اند؛ بنابراین نمی‌توان فهمید کدام عامل زودتر رخ داده یا یکی علت دیگری است.
- خودگزارشی بودن: اطلاعات سیگار و علائم افسردگی بر اساس پاسخ افراد ثبت شده‌اند و ممکن است دقیق نباشند. همچنین گروه «هرگز» می‌تواند افرادی را شامل شود که کمتر از ۱۰۰ نخ سیگار کشیده‌اند.
- داده‌های ناقص: تعدادی از افراد به دلیل ناقص بودن پاسخ‌های PHQ-9از تحلیل حذف شدند و برای بعضی افراد نیز اطلاعات درآمد وجود نداشت. این حذف‌ها ممکن است بر نتایج اثر بگذارند.
- نمونه‌گیری: برای تعمیم نتایج باید وزن‌ها و اطلاعات مربوط به طبقه‌ها و واحدهای نمونه‌گیری در محاسبات لحاظ شوند.
- تفاوت گروه‌ها: گروه‌های سیگار از نظر سن، جنس و درآمد یکسان نیستند؛ بنابراین تفاوت نمره‌های افسردگی را نمی‌توان فقط به سیگار نسبت داد.

منابع

۱. National Center for Health Statistics, CDC. National Health and Nutrition Examination Survey, August 2021–August 2023: data files and documentation.

۲. CDC/NCHS. NHANES sample design and analytic guidance for the 2021–2023 cycle.

۳. Wonnacott, T. H., and Wonnacott, R. J. Introductory Statistics, 5th ed., Wiley.